《Python 科学计算与数据处理》结课报告

用 Python 爬虫实现网络小说和桌面壁纸的批量下载

姓　名：承子杰

学　号：202228000243001

研究所：　数学与系统科学研究院

一、 报告简介

本篇报告主要讲述使用 Python 爬虫进行网络信息的抓取。作者首先将介绍实现 Python 爬虫所需要的一些基础模块，例如 requests 模块、re 模块、Etree 模块等、正则表达式的初步知识、多线程下载与线程池的使用的一些基础内容。之后作者将通过一个实例---爬取英文网络小说计算语言信息熵---来展示具体实现流程，从而进一步地加深读者对 Python 爬虫的了解与使用，方便大家在今后的应用过程中编写自己所需要爬虫程序。

二、 基础知识介绍

1） Requests 模块简介

1. Requests 模块背景

   Requests 模块是使用 Apache2 Licensed 许可证的基于 Python 开发的 HTTP 库，其在 Python 内置模块（urllib3）的基础上进行了高度的封装，从而使得用户在进行网络请求时，变得方便了许多。Requests 支持 HTTP 连接保持和连接池，支持使用 cookie 保持会话，支持文件上传，支持自动确定响应内容的编码，支持国际化的 URL 和 POST 数据自动编码等多种功能，基本上能完全满足当前网络的各种需求。

2. Requests 模块的安装

   Requests 模块是 Python 的第三方库，我们可以使用 pip install 命令来进行安装，具体代码如下：

   ```
   pip install requests
   ```

3. Requests 模块提供的请求方法。

   Requests 提供了如下五种基本的请求方法：

   - GET： 请求指定的页面信息，并返回实体主体。
   - HEAD： 只请求页面的首部。
   - POST： 请求服务器接受所指定的文档作为对所标识的 URI 的新的从属实体。
   - PUT： 从客户端向服务器传送的数据取代指定的文档的内容。
   - DELETE： 请求服务器删除指定的页面。

   对于一般的网络爬虫而言，GET 请求和 POST 请求使用较多，下面我们对这两个方法进行详细的介绍。

4. GET 请求

基本的 GET 请求

使用的基本语法如下：

```
import requests   #导入模块
#使用 get 方法请求 url，会得到一个 response 对象
response = requests.get(url)
```

带请求头 headers 的 GET 请求

有些网站在访问时必须带有浏览器等信息，我们可以设置请求头伪装成浏览器浏览。例如，在爬取豆瓣书评网站时，若不设置请求头，则会访问失败。

```
import requests

url = "https://book.douban.com"
#  不设置请求头
resp = requests.get(url)
#  打印请求结果代码
print(resp.status_code)

Result：
418 #  请求成功打印数字 200
```

下面我们设置参数 headers，headers 需要写成一个字典的形式，基本格式如下：

```
headers = {
 'User-Agent': 'Mozilla/5.0 (Macintosh; Intel Mac OS X 10_11_4)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/52.0.2743.116
Safari/537.36'
}
```

其中字典的键是固定的，为 'User-Agent'，其键值可以在浏览的网页中打开页面源码（作者使用的 Google Chrome 浏览器可以网页右击选择检查打开），选择网络菜单，打开对应网页的标头选项中可以查找到相应信息。

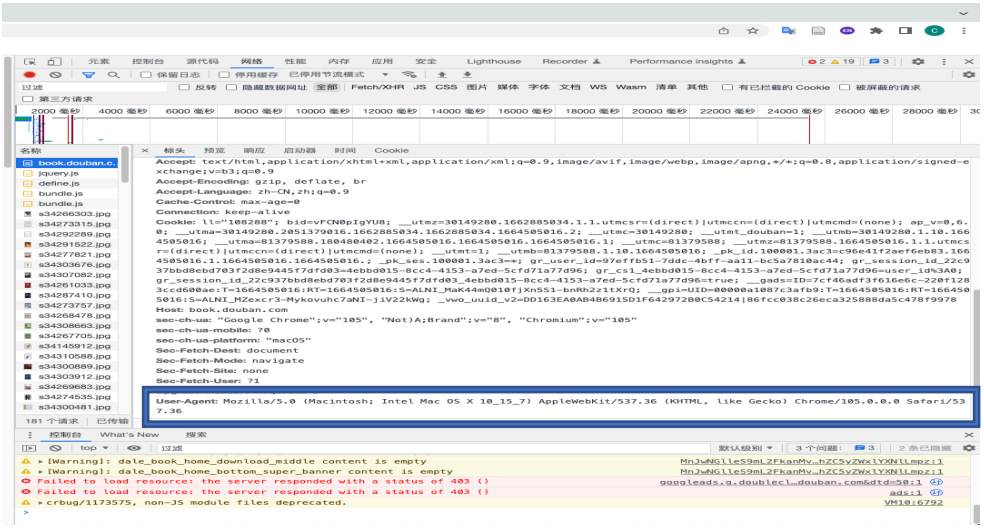

作者在此处显示的值如下。

```
User-Agent: Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/105.0.0.0 Safari/537.36
```

此处显示了基本的浏览器信息与访问设备信息，现在我们加入请求头，重新测试爬取结果。

```
import requests

url = "https://book.douban.com"
# 设置请求头
headers = {'User-Agent': 'Mozilla/5.0 (Macintosh; Intel Mac OS X 10_15_7)
AppleWebKit/537.36 (KHTML, like Gecko) Chrome/105.0.0.0 Safari/537.36'}
resp = requests.get(url,headers=headers)
# 打印请求结果代码
print(resp.status_code)

Result:
200 # 请求成功
```

5. POST 请求

   post() 方法类似于 GET()方法，可以发送 POST 请求到指定 url，其一般的语法格式如下：

```
requests.post(url, data={key: value}, json={key: value}, args)
```

   其中：

   - **url**：请求 url。
   - **data** 参数：为要发送到指定 url 的字典、元组列表、字节或文件对象。
   - **json** 参数：为要发送到指定 url 的 JSON 对象。
   - **args** 为其他参数，比如 cookies、headers、verify 等。

6. Response 响应属性

   POST()方法与 GET()的返回值都是都是一个 response 对象，比较常用的属性如下：

属性或方法	说明
close()	关闭与服务器的连接
encoding	解码 r.text 的编码方式
headers	返回响应头，字典格式

ok	检查 "status_code" 的值，如果小于 400，则返回 True，如果不小于 400，则返回 False
reason	响应状态的描述，比如 "Not Found" 或 "OK"
request	返回请求此响应的请求对象
status_code	返回 http 的状态码，比如 404 和 200（200 是 OK，404 是 Not Found）
text	返回响应的内容，unicode 类型数据
url	返回响应的 URL

2） 正则表达式基础知识与 Re 模块简介

1. 正则表达式的定义

正则表达式是对字符串（包括普通字符（例如，a 到 z 之间的字母）和特殊字符（称为“元字符”））操作的一种逻辑公式，就是用事先定义好的一些特定字符、及这些特定字符的组合，组成一个“规则字符串”，这个“规则字符串”用来表达对字符串的一种过滤逻辑。正则表达式是一种文本模式，该模式描述在搜索文本时要匹配的一个或多个字符串。

2. 正则表达式的基本语法

表达式	**描述**
X, a, 9, <	普通字符的完全匹配
.	匹配任何单个字符，除了换行符’\n’
\w	匹配“单词”字符：字母或数字或下划线[a-zA-Z0-9_]
\b	字词与非字词之间的界限
\s	匹配单个空格字符-空格、换行符，返回，制表符
\S	匹配任何非空格字符
\t, \n, \r	匹配制表符、换行符、退格符
\d	匹配十进制数[0-9]
^	匹配字符串的开头
$	匹配字符串的末尾
\	抑制字符的特殊性，即转义字符。

3. 正则表达式的特殊语法

表达式	描述
<.*>	贪婪重复
<.*?>	非贪婪重复
[a-z]	匹配任何小写字母
[A-Z]	匹配任何大写字母
[0-9]	匹配任何数字
[\u4e00-\u9fa5]	匹配所有汉字

4. Re 模块背景

Re 模块是 Python 的标准库，它使 Python 语言拥有全部的正则表达式功能。该模块提供了一些关于正则表达式操作的函数，这些函数使用一个模式字符串做为它们的第一个参数，下面我们将对常用的几个函数进行详细的介绍。

5. match 函数

match 函数从字符串的最开始与 pattern 进行匹配，下面是该函数的基本语法 ：

re.match(pattern, string, flags = 0)

其中：

- pattern - 这是要匹配的正则表达式。
- string - 这是字符串，它将被搜索用于匹配字符串开头的模式。
- flags - 可以使用按位 OR(|)指定不同的标志。这些是修饰符，如下表所列。

当 re.match 函数匹配成功时，会返回匹配对象，失败时则返回 None。使用 match(num)或 groups()函数可以匹配对象来获取匹配的表达式。

下面是一个使用 match 函数的例子。

```
#未从初始位置匹配，会返回 None
import re

line = 'i can speak good english'
matchObj = re.match(r'(i)\s(\w*)\s(\w*).*',line)
```

```
if matchObj:
      print('matchObj.group() :',matchObj.group())
      print('matchObj.group(1) :',matchObj.group(1))
      print('matchObj.group(2) :',matchObj.group(2))
      print('matchObj.group(3) :',matchObj.group(3))
else:
      print('no match!')
```

Result:

```
matchObj.group() : i can speak good english
matchObj.group(1) : i
matchObj.group(2) : can
matchObj.group(3) : speak
```

6. search 函数

search 函数与 match()工作的方式类似，但是 search()不是从最开始匹配的，而是从任意位置查找第一次匹配的内容。下面是这个函数的语法 ：

re.search(pattern, string, flags = 0)

其中：

- pattern - 这是要匹配的正则表达式。
- string - 这是字符串，它将被搜索用于匹配字符串开头的模式。
- flags - 可以使用按位 OR(|)指定不同的标志。这些是修饰符，如下表所列。

当 re.research 函数匹配成功时，会返回匹配对象，失败时则返回 None。使用 match(num)或 groups()函数可以匹配对象来获取匹配的表达式。

下面是一个使用 search 函数的例子。

```
import re

line = 'i can speak good english'
searchObj = re.search(r'\s(\w*)\s(\w*).*',line)
if searchObj:
      print('searchObj.group() :',searchObj.group())
      print('searchObj.group(1) :',searchObj.group(1))
      print('searchObj.group(2) :',searchObj.group(2))
else:
print('no match!')
```

Result:

```
searchObj.group() :    can speak good english
searchObj.group(1) : can
searchObj.group(2) : speak
```

7. sub 函数

re 模块中使用频率最多的函数应该是 sub 函数。此方法使用 repl 替换所有出现在模式里的字符串，并且替换所有次的出现，除非提供了参数 max。此方法返回修改的字符串，一般的语法格式如下：

```
re.sub(pattern, repl, string, max=0)
```

8. compile 函数

compile 函数用于编译正则表达式，生成一个 Pattern 对象，它的一般使用形式如下：

```
re.compile(pattern[, flag])
```

参数含义与上面函数类似，这里不再做过多解释。

9. findall 函数

findall 函数返回包含所有匹配项的列表。返回 string 中所有与 pattern 相匹配的全部字串，返回形式为数组。它的一般使用形式如下：

```
re.findall(pattern, string, flags=0)
```

findall 函数一般与 compile 函数连用，下面我们举一个例子。

```
import re

line = 'a0bb3c45djs8'
obj = re.compile(r"[0-9]")
result = obj.findall(line)
print(result)


Result:
['0', '3', '4', '5', '8']
```

3） Etree 模块简介

1. LXML 模块

Python 的 lxml 模块是 XML 和 HTML 的解析器，其主要功能是解析和提取 XML 和 HTML 中的数据。lxml 和正则一样，也是用 C 语言实现的，是一款高性能的解析器。该模块也可以利用 XPath 语法，来定位特定的元素及节点信息。

- HTML 是超文本标记语言，主要用于显示数据，他的焦点是数据的外观。
- XML 是可扩展标记语言，主要用于传输和存储数据，他的焦点是数据的内容。

2. Etree 模块

Etree 模块是 LXML 库下的一个子模块，本报告中主要使用了该模块下的 HTML 函数和 xpath 函数，下面作者将对这两个函数做一个简单的介绍。

3. LXML 模块的安装

LXML 模块是 Python 的第三方库，我们可以使用 pip install 命令来进行安装，具体代码如下：

```
pip install xlml
```

4. Etree.HTML 函数

etree.HTML()函数可以用来解析字符串格式的 HTML 文档对象，将传进去的字符串转变成_Element 对象。作为_Element 对象，可以方便的使 xpath()等方法进行字符串匹配等操作。

5. Etree.xpath 函数

etree.xpath 函数可以根据提供的 xpath 表达式，匹配出所需要的 html 内容，其基本语法格式如下：

```
result = et.xpath('xpath 表达式')
```

下面我们对 xpath 表达式进行一些简单介绍。

6. Xpath 表达式介绍

表达式	描述
'/'	表示从根节点开始定位，表示一个层级
'//'	表示多个层级，开头时表示从任意位置开始定位
'./'	表示从当前标签开始定位
'标签名[@属性名="属性值"]'	属性定位
'标签名[索引]'	索引定位，索引从 1 开始
'xpath 表达式 1|xpath 表达式 2'	多重定位
标签名/text()	获取直系文本
标签名/@属性名	获取非直系文本
标签名/@属性名	获取属性值

4） 多线程下载与线程池

1. 线程与进程

下面我们对线程和进程做一些基本的介绍。

- 进程：计算机程序只是存储在磁盘中的可执行二进制(或其他类型)的文件。只有把他们加载到内存中并被操作系统调用，才具有其生命周期。进程则是一个执行中的程序。每个进程都拥有自己的地址空间，内存，数据栈以及其他用于跟踪执行的辅助数据。进程也可以通过派生新的进程来执行其他任务。由于每个进程有自己的数据，所以只能采用进程间通信(IPC)的方式来共享信息。
- 线程：又称轻量级进程。一个进程开始便会创建一个线程，称为主线程。一个进程可以创建多个线程，多线程即是同一进程下的不同执行路径，同一进程下的线程共享该进程的数据区。线程以并发的方式执行，线程执行时可以被中断和挂起。(在多核 cpu 中，多线程才可能并行执行)

2. Thread 与 Threading 模块

Python 提供多线程模块 thread 及 threading，以及队列 Queue，其中 thread 相对比较基础，不容易控制，官方建议使用 threading 模块，thread 模块在 python3 版本中被重命名为_thread。由于 thread 与 threading 模块需要创建线程，使用完成后需要手动回收线程，相对较为麻烦。于此同时，对于不同大小的问题，我们有时并不知道应该安排多少线程较为合适，而且手动创建多线程需要提供相关锁的程序作为线程守护，否则容易出现问题。因此综上所示，我们选择使用线程池来代替手动创建多线程。

3. 线程池的优点

- 创建合理的线程数量，重用存在的线程，减少线程创建销毁带来的开销。
- 可有效的控制最大并发线程数，提高系统资源的使用率，同时避免过多资源竞争，避免堵塞。提供定时执行、定期执行、单线程、并发数控制等功能。

4. ThreadPoolExecutor 模块

ThreadPoolExecutor 位于 Python3 标准库的并发包（concurrent.futures）下，我们可以使用该模块非常简单的创建和使用线程池。该模块具有如下几个特点；

- 主线程可以获取某一个线程的状态，以及返回值。

- 线程同步。
- 让多线程和多进程的编码接口一致。
- 简单粗暴。

5. 多线程的基本使用方法

在这里，我们仅提供一个例子，简单介绍如何使用多线程，对于多线程的详细介绍可以参考相关文档。

```
# 创建一个包含 2 条线程的线程池
with ThreadPoolExecutor(max_workers=2) as pool:
# 另一种方式
# pool = ThreadPoolExecutor(max_workers=2)
# 向线程池提交一个 task, 20 会作为 action()函数的参数
task = pool.submit(action, 20)
# 向线程池再提交一个 task, 30 会作为 action()函数的参数
task2 = pool.submit(action, 30)
# 判断 task 代表的任务是否结束
print(task.done())
time.sleep(3)
# 判断 task2 代表的任务是否结束
print(task2.done())
# 查看 task 代表的任务返回的结果
print(task.result())
# 查看 task2 代表的任务返回的结果
print(task2.result())
# 关闭线程池
pool.shutdown()
```

三、 实际案例分析

爬取英文网络小说并计算英语语言的信息熵

1. 问题分析

作者打算爬取英文小说网站：https://engnovel.com 上当期最流行的一本英语小说。该问题主要分为如下几个步骤：

- 爬取本网站最流行小说排行榜上第一位小说的详情页 url。
- 在获得 url 后，向该 url 发送请求，获得该小说详情页中目录下第一个章节的 url 和最后一个章节的 url。因为该小说详情页的第一页只提供了部分的章节 url，其余章节需要翻页获得 url。
- 向第一章的 url 发送请求，注意到返回到 HTML 文件中除了小说该章节的内容之外，还有下一章的 url。
- 我们再次向下一章的章节发送请求，重复上述操作，模拟翻页的过程，直到最后一章。我们在之前已经获得了最后一章的 url，故可以判断是否结束循环。
- 对于每一章的 HTML 文件，做一定的字符串匹配，获得小说内容，并写入文件

- 小说内容的清洗与熵的计算。

2. 实际操作

下面我们就按上述内容一步一步操作。首先是获得最流行小说详情页的 url。我们需要编写一个名为 get_detail_href 的函数，输入值为最流行小说排行榜的 url，输出是最流行小说详情页的 url，具体代码如下：

```
def get_detail_href(url):
    """
    该函数负责获取到详情页的值
    """
    print("开始分析主界面")
    # 向指定 url 发送请求
    resp = requests.get(url)
    # 定义编码形式
    resp.encoding = "utf-8"
    # 解析获得的 response 请求结果，获得 html
    et = etree.HTML(resp.text)
    # 使用 xpath 表达式匹配到指定信息
    hrefs = et.xpath("//div[@class = 'each_truyen']/a/@href")
    print("分析完成")
    # 返回 url 链接
    return hrefs[0]
```

现在我们已经获得了当期最流行小说排行榜第一的小说(PEERLESS MARTIAL GOD)详情页的 URL。我们现在需要编写一个函数 get_page_srcs 来获得详情页目录中小说第一章的 URL 和最后一章的 url，具体的代码如下

```
def get_page_srcs(url):
    print("开始抓取子页面")
    # 请求小说详情页
    resp = requests.get(url)
    # 定义编码形式
    resp.encoding = "utf-8"
    # 解析获得的 response 请求结果，获得 html
    et = etree.HTML(resp.text)
    # 使用 xpath 表达式匹配到指定信息
    hrefs = et.xpath("//ul[@class='list-chapter']/li/a/@href")
    # 从多个目录列表中筛选出第一章和最后一章的 url
    hrefs = [hrefs[0], hrefs[6]]
    print("抓取成功")
    # 返回 URL 列表
    return hrefs
```

现在我们已经获得了第一章和最后一章（第 2500 章）的 url，下面我们编写一个函数 download_text，可以打开对应章节的 url，爬取章节页的内容，并且可以模拟点击下一章的操作，从而可以爬取整本小说（建议在连接有线网或网络稳定的情况下进行操作，不然容易失败，或者爬取时间较长。此处由于存在顺序结构，无法使用线程池加快速度，可以考虑在小说目录页模拟翻页操作，将所有的章节 url 获得，再使用线程

池完成任务）。函数的输入项 src1 是起始页的 url，src2 是最后页的 url，该函数没有输出项，爬去内容直接写入了 text 文件。函数的具体代码如下：

```
# src1：下载小说起始页 url，src2：终止页 url
def download_text(src1, src2):
    # 下载章节计数器
    t = 0
    print("开始下载章节")
    while True:
        # 请求对于章节的 url
        resp = requests.get(src1)
        # 定义返回 response 对象编码形式
        resp.encoding = "utf-8"
        # 定义正则表达式
        obj = re.compile(r'<p>(.*?)</p>', re.S)
        # 使用正则表达式匹配返回的 html 页面，得到章节小说内容
        content1 = obj.findall(resp.text)
        # 将返回的列表转化为字符串
        content = "".join(content1)
        # 做初步的内容清洗，将&#8230 转译为"..."
        content = content.replace("&#8230", "...")
        # 编写写入函数，写入程序文件下的 book.text 文件，写入方式是追加
        with open(f"book", mode="a") as f:
            f.write(content)
        # 判断是否是最后一页，或者章节下载次数超过 5000，提高程序的鲁棒性
        if src1 == src2 or t > 5000:
            break
        # 用 xpath 的方法匹配出下一章节的 url
        et = etree.HTML(resp.text)
        src1 = et.xpath('//a[@id = "next_chap" ]/@href')[0]
        # 计数器加一
        t = t + 1
        print(t)
    print("下载本书完毕")
```

必要的功能性函数写完之后，我们需要写一个 main 函数来统筹一下各个流程，具体的代码如下：

```
def main():
    url = "https://engnovel.com/most-popular-novels"
    # 1. 抓取到首页中详情页到 href
    hrefs = get_detail_href(url)
    # 2. 获得第一章和最后一章的 url
    page_src_list = get_page_srcs(hrefs)
    # 3. 下载小说
```

```
download_text(page_src_list[1],page_src_list[0])
```

在我们获取到这本小说的主要内容后，我们来计算一下这本书中文字的信息熵和各个字母的信息熵。要完成这个任务，我们需要进行如下几个步骤的操作：

1. 读取小说文本
2. 清洗文本，将获得的小说内容除英文字母外全部清洗掉。
3. 统计各个单词的词频
4. 计算各个字母的信息熵和英文整体的熵。

对于如上四个问题，我们分别编写了如下四个函数来完成相应的任务。

1. **读取文件内容函数** read_text

```
# 读取文件内容
def read_text():
# 打开小说文件，模式是 read
    with open(f"book", mode="r") as f:
    # 将读取的文件赋值给 text
        text = f.read()
# 关闭文件
        f.close()
# 返回读取的内容
        return text
```

2. **文本清洗函数** text_clean

```
# 文本清洗
def text_clean(text):
# 使用正则表达式去除除字母以外的所有符号
    obj = re.compile("[^A-Za-z]")
    text = obj.sub("", text)
    # 将所有字母全部转化为小写，方便统计词频
    text = text.lower()
    # 返回处理后的文本
    return text
```

3. **统计词频函数** count_alpha

```
# 统计词频
def count_alpha(text, num):
# 统计[0,num-1]区间段的文字
    text = text[0:num - 1]
    # 使用 Counter 函数统计
    count = Counter(text)
    # 将结果赋值给 result
    result = count.most_common()
    return result
```

4. **计算熵的函数** entropy_cal

```
# 计算熵的函数
def entropy_cal(alpha_num):
```

```
    # 读取字母列表
    alpha_num_list = np.array(alpha_num)
    # 读取各个字母的词频
    num = np.array(alpha_num_list[:, 1], dtype="int64")
    alpha = np.array(alpha_num_list[:, 0])
    # 计算总词频
    total_num = np.sum(num)
    # 计算各个词的频率
    num_prob = np.divide(num, total_num)
    # 计算频率对数
    log2_num_prob = np.log2(num_prob)
    # 各个字母的熵
    en_alpha = -np.multiply(num_prob, log2_num_prob)
    # 计算英语语言熵
    en_total = -np.dot(num_prob, log2_num_prob)
    # 拼接字典，返回结果
    result = dict(np.c_[alpha, en_alpha])
    result['total'] = en_total
    return result
```

最后我们编写一个 main 函数来统筹各个函数，完成 5000 个单词逐步加入样本，计算样本下的熵，观测其变化趋势，main 函数的具体代码如下：

```
def main():
    # 读取文本
    text = read_text()
    # 清洗文本
    text = text_clean(text)
    # 以 5000 个字母为统计单位，依次加入计算熵，观察趋势
    length = len(text)
    # 计算加入次数
    num = length // 5000
    alpha_num = count_alpha(text, length)
    entropy_cal(alpha_num)
    # 绘制各个英语字母的熵的趋势图
    for alpha in [chr(i) for i in range(97, 123)]:
        total = []
        y = []
        for i in range(num):
            if i == num - 1:
                alpha_num = count_alpha(text, length)
                total.append(round(float(entropy_cal(alpha_num)[f"{alpha}"]),
3))
                y.append(length)
            else:
                alpha_num = count_alpha(text, (i + 1) * 5000)
```

```
                total.append(round(float(entropy_cal(alpha_num)[f'{alpha}']),
3))
                y.append((i + 1) * 5000)
        plt.plot(y, total, 'r-')
        plt.xlabel("Number of Words")
        plt.ylabel("Entropy")
        plt.title(f'Word "{alpha}" Entropy Tendency')
        plt.savefig(f"Entropy_EN/{alpha}.jpg")

    # 绘制英语语言熵的趋势图
    total = []
    y = []
    for i in range(num):
        if i == num - 1:
            alpha_num = count_alpha(text, length)
            total.append(round(float(entropy_cal(alpha_num)["total"]), 3))
            y.append(length)
        else:
            alpha_num = count_alpha(text, (i + 1) * 5000)
            total.append(round(float(entropy_cal(alpha_num)["total"]), 3))
            y.append((i + 1) * 5000)
    plt.plot(y, total, 'r-')
    plt.xlabel("Number of Words")
    plt.ylabel("Entropy")
    plt.title('Total Entropy Tendency')
    plt.savefig("Entropy_EN/total.jpg")
    plt.close()
```

最后的计算结果如下：

英语语言的总熵趋势图：

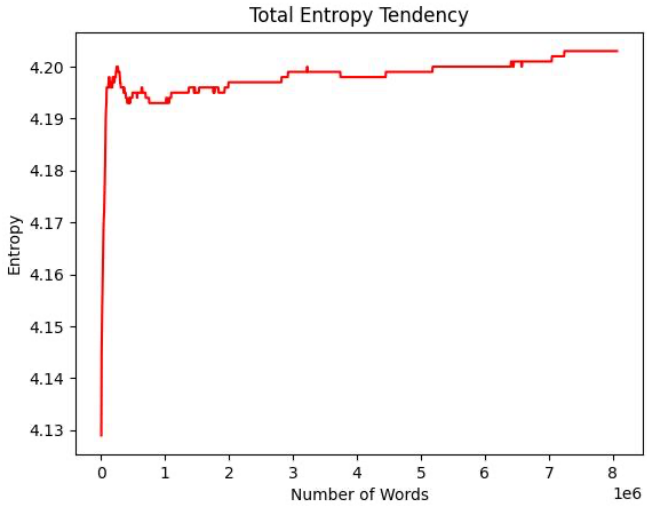

各个字母的信息熵趋势图：

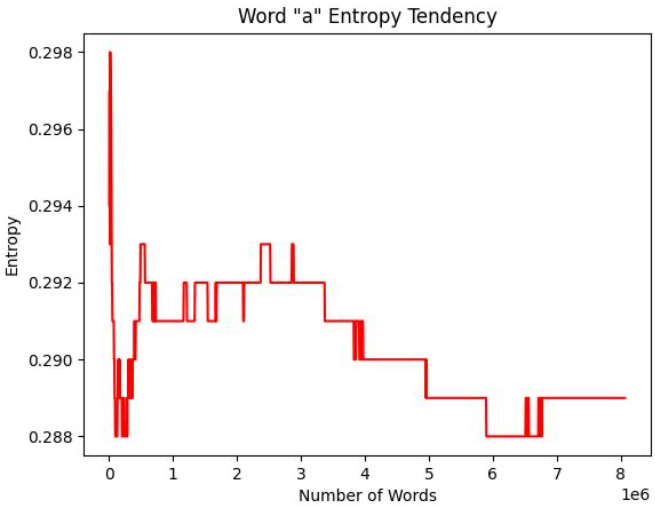
Word "a" Entropy Tendency
Entropy
0.298
0.296
0.294
0.292
0.290
0.288
0 1 2 3 4 5 6 7 8
Number of Words
1e6

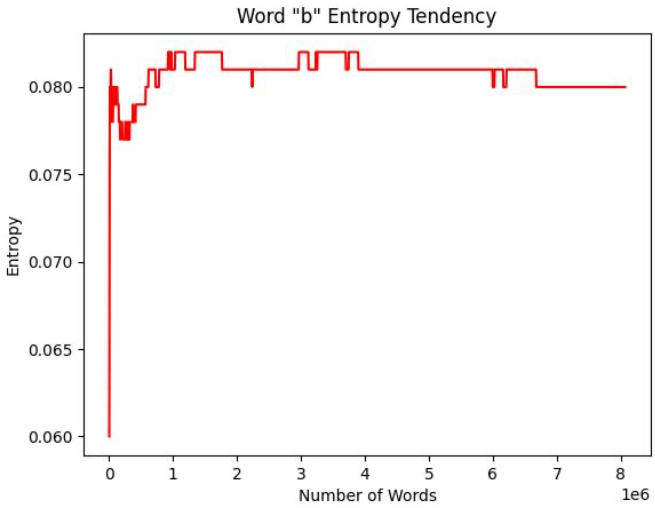
Word "b" Entropy Tendency
Entropy
0.080
0.075
0.070
0.065
0.060
0 1 2 3 4 5 6 7 8
Number of Words
1e6

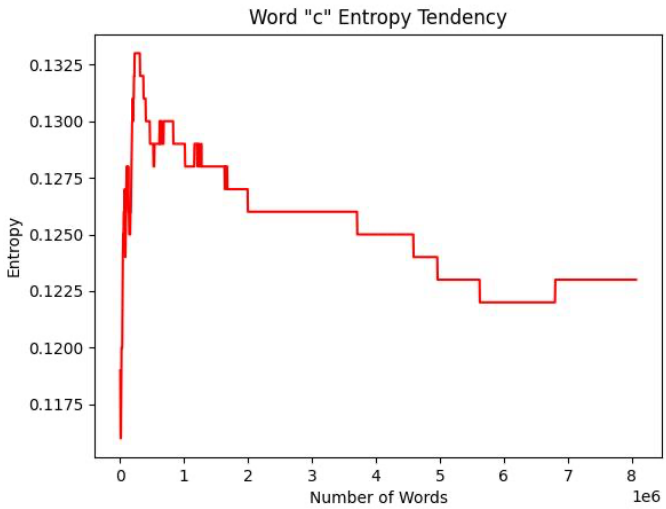
Word "c" Entropy Tendency
Entropy
0.1325
0.1300
0.1275
0.1250
0.1225
0.1200
0.1175
0 1 2 3 4 5 6 7 8
Number of Words
1e6

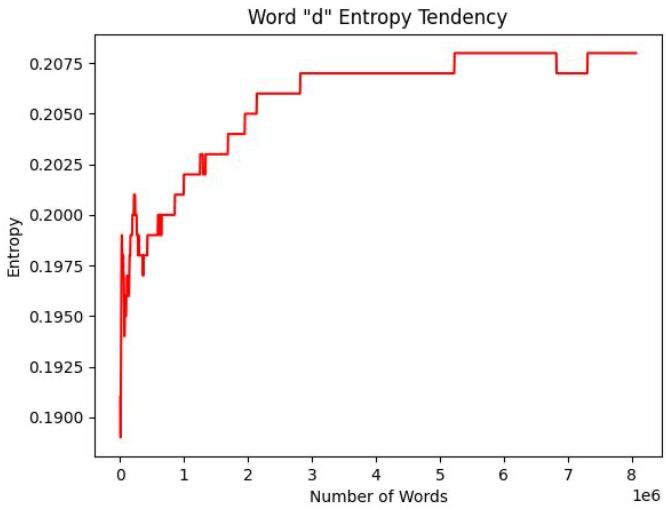
Word "d" Entropy Tendency
Entropy
0.2075
0.2050
0.2025
0.2000
0.1975
0.1950
0.1925
0.1900
0 1 2 3 4 5 6 7 8
Number of Words
1e6

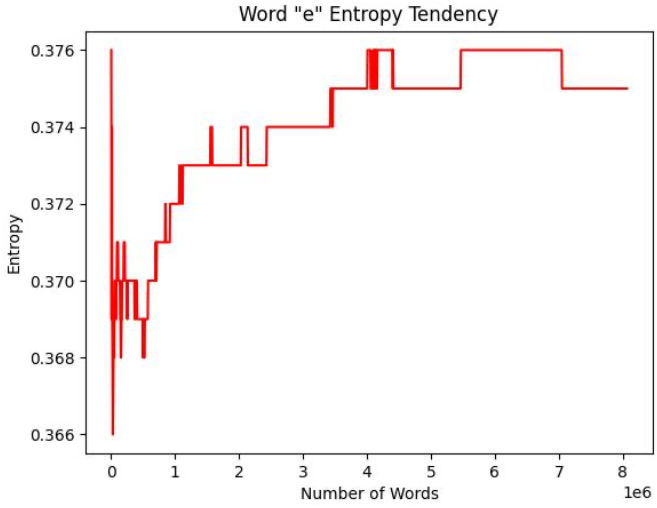
Word "e" Entropy Tendency
Entropy
0.376
0.374
0.372
0.370
0.368
0.366
0 1 2 3 4 5 6 7 8
Number of Words
1e6

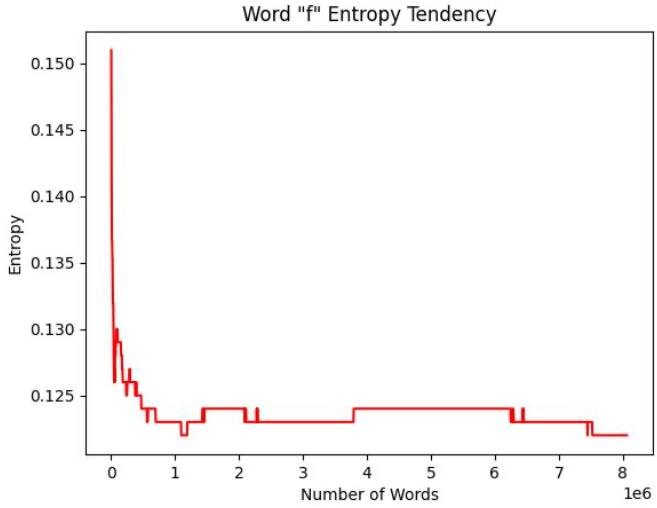
Word "f" Entropy Tendency
Entropy
0.150
0.145
0.140
0.135
0.130
0.125
0 1 2 3 4 5 6 7 8
Number of Words
1e6

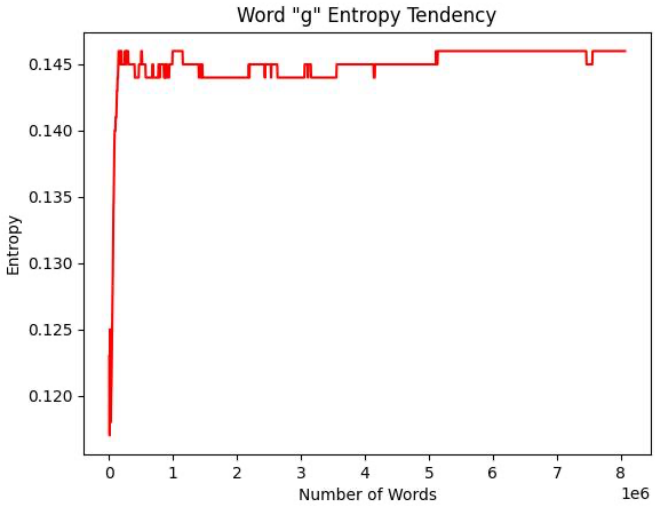
Word "g" Entropy Tendency
Entropy
0.145
0.140
0.135
0.130
0.125
0.120
0
1
2
3
4
5
6
7
8
Number of Words
1e6

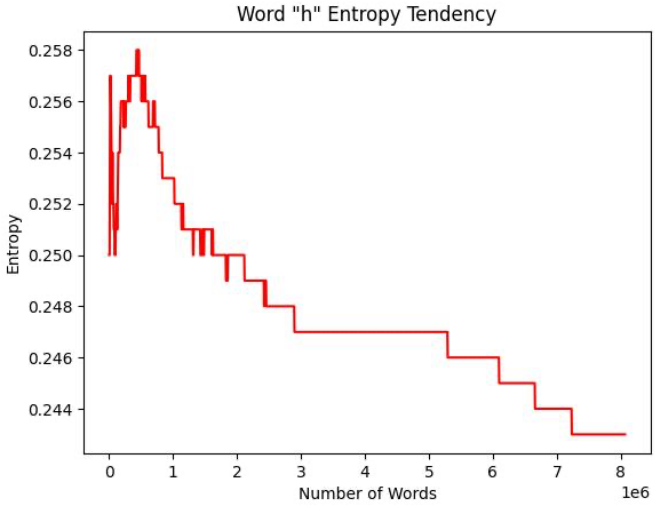
Word "h" Entropy Tendency
Entropy
0.258
0.256
0.254
0.252
0.250
0.248
0.246
0.244
0
1
2
3
4
5
6
7
8
Number of Words
1e6

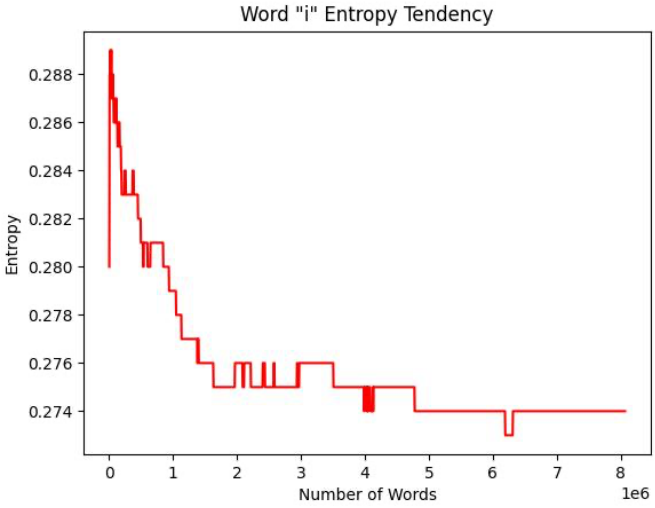
Word "i" Entropy Tendency
Entropy
0.288
0.286
0.284
0.282
0.280
0.278
0.276
0.274
0
1
2
3
4
5
6
7
8
Number of Words
1e6

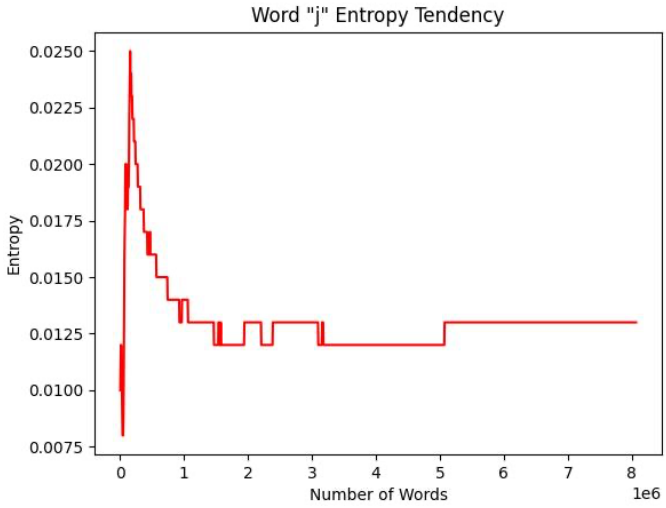
Word "j" Entropy Tendency
Entropy
0.0250
0.0225
0.0200
0.0175
0.0150
0.0125
0.0100
0.0075
0 1 2 3 4 5 6 7 8
Number of Words
1e6

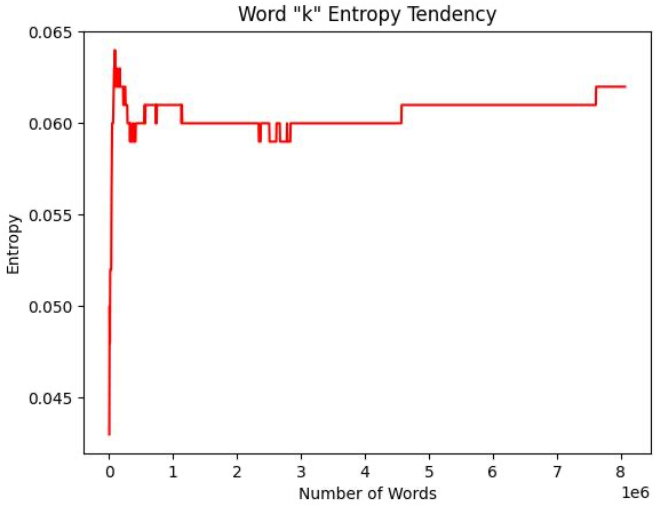
Word "k" Entropy Tendency
Entropy
0.065
0.060
0.055
0.050
0.045
0 1 2 3 4 5 6 7 8
Number of Words
1e6

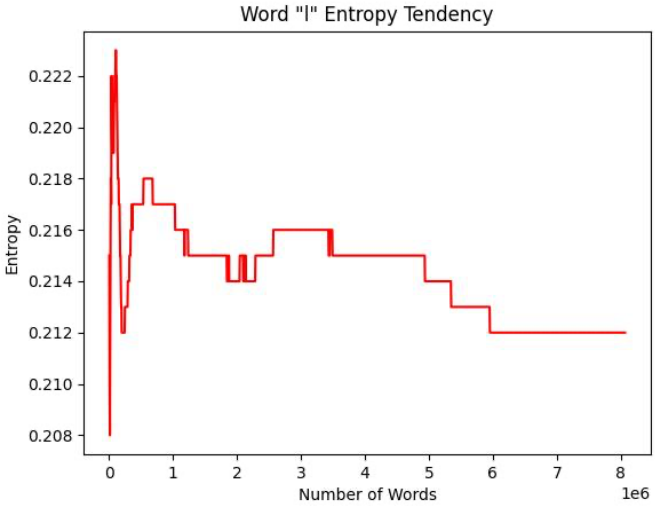
Word "l" Entropy Tendency
Entropy
0.222
0.220
0.218
0.216
0.214
0.212
0.210
0.208
0 1 2 3 4 5 6 7 8
Number of Words
1e6

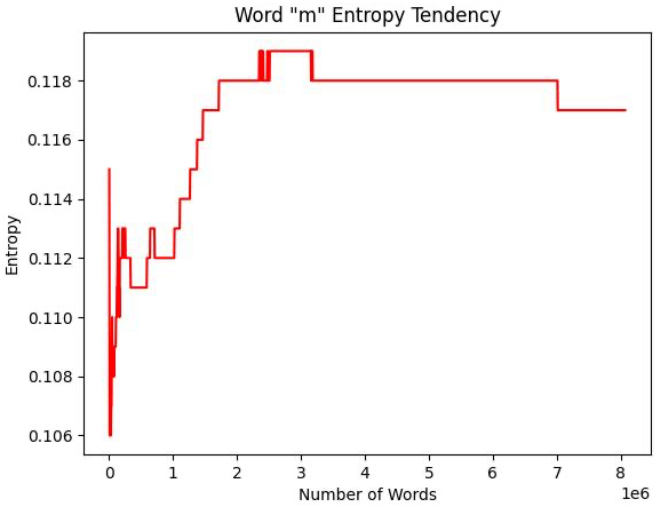
Word "m" Entropy Tendency
Entropy
0.118
0.116
0.114
0.112
0.110
0.108
0.106
0 1 2 3 4 5 6 7 8
Number of Words
1e6

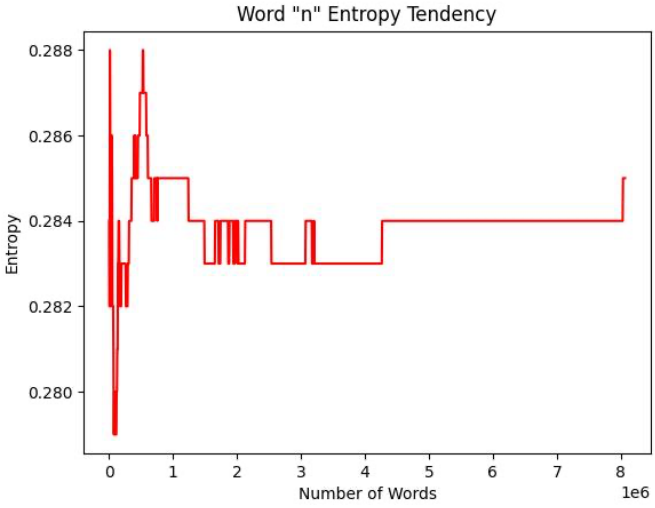
Word "n" Entropy Tendency
Entropy
0.288
0.286
0.284
0.282
0.280
0 1 2 3 4 5 6 7 8
Number of Words
1e6

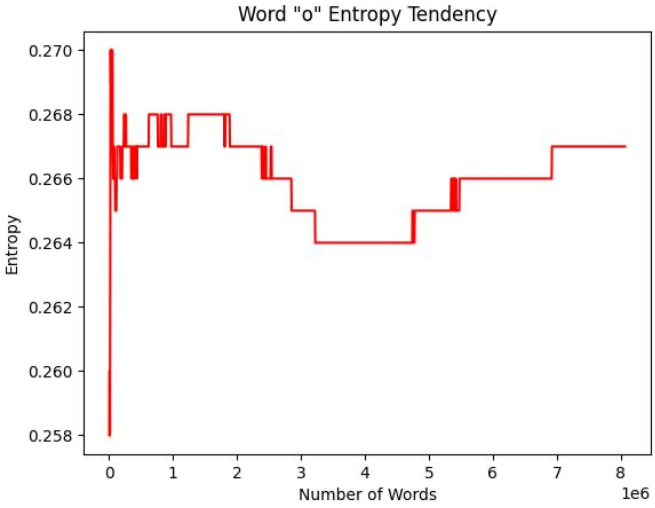
Word "o" Entropy Tendency
Entropy
0.270
0.268
0.266
0.264
0.262
0.260
0.258
0 1 2 3 4 5 6 7 8
Number of Words
1e6

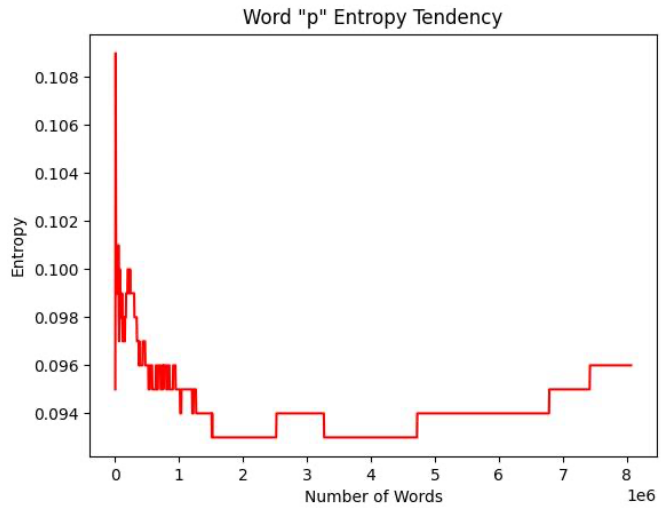
Word "p" Entropy Tendency
Entropy
0.108
0.106
0.104
0.102
0.100
0.098
0.096
0.094
0 1 2 3 4 5 6 7 8
Number of Words
1e6

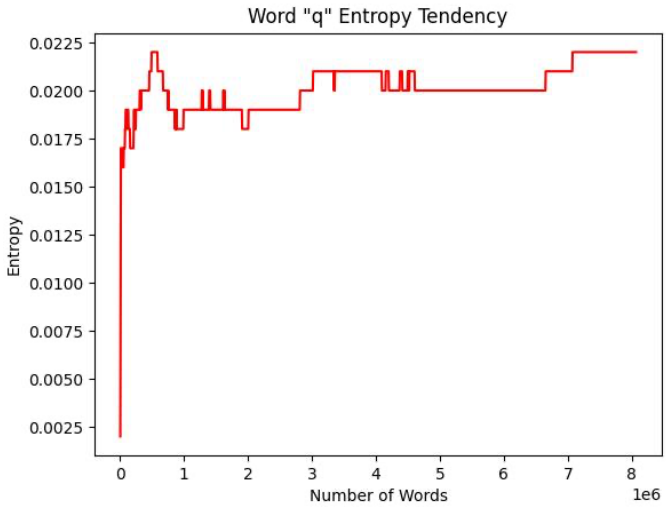
Word "q" Entropy Tendency
Entropy
0.0225
0.0200
0.0175
0.0150
0.0125
0.0100
0.0075
0.0050
0.0025
0 1 2 3 4 5 6 7 8
Number of Words
1e6

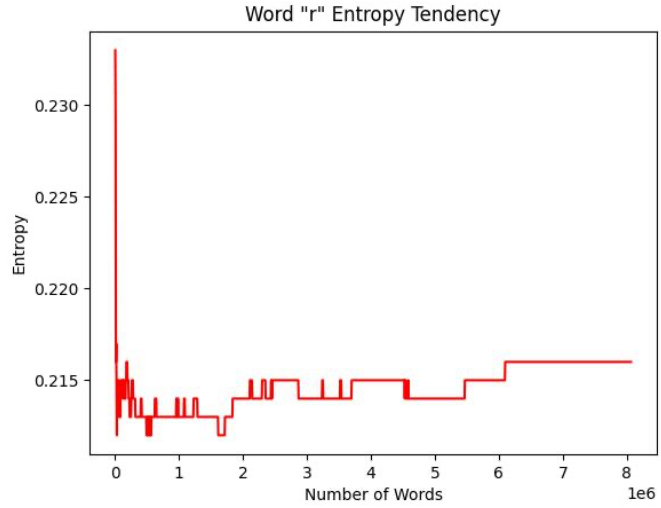
Word "r" Entropy Tendency
Entropy
0.230
0.225
0.220
0.215
0 1 2 3 4 5 6 7 8
Number of Words
1e6

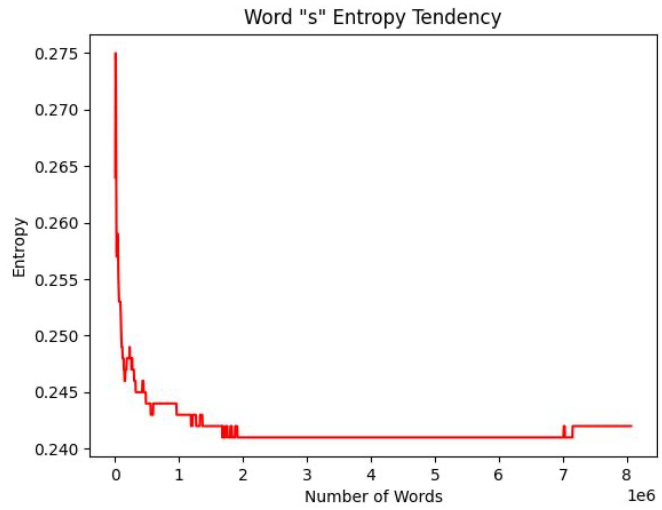
Word "s" Entropy Tendency
Entropy
0.275
0.270
0.265
0.260
0.255
0.250
0.245
0.240
0 1 2 3 4 5 6 7 8
Number of Words
1e6

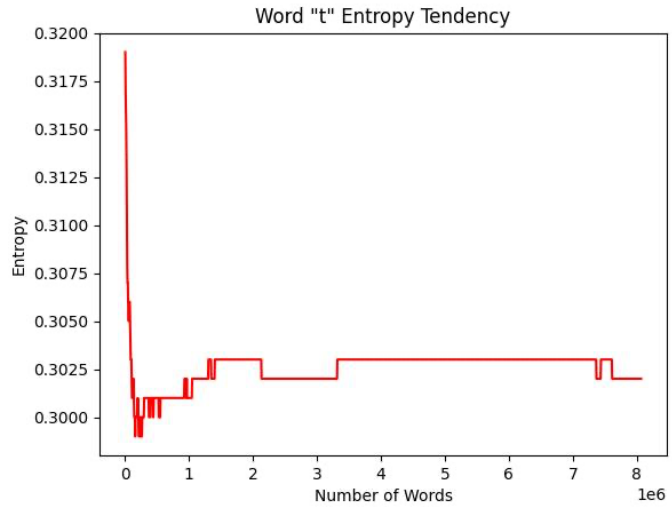
Word "t" Entropy Tendency
Entropy
0.3200
0.3175
0.3150
0.3125
0.3100
0.3075
0.3050
0.3025
0.3000
0 1 2 3 4 5 6 7 8
Number of Words
1e6

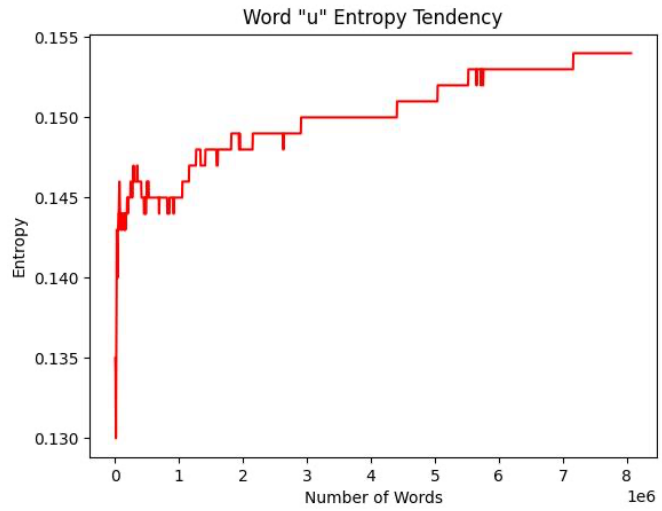
Word "u" Entropy Tendency
Entropy
0.155
0.150
0.145
0.140
0.135
0.130
0 1 2 3 4 5 6 7 8
Number of Words
1e6

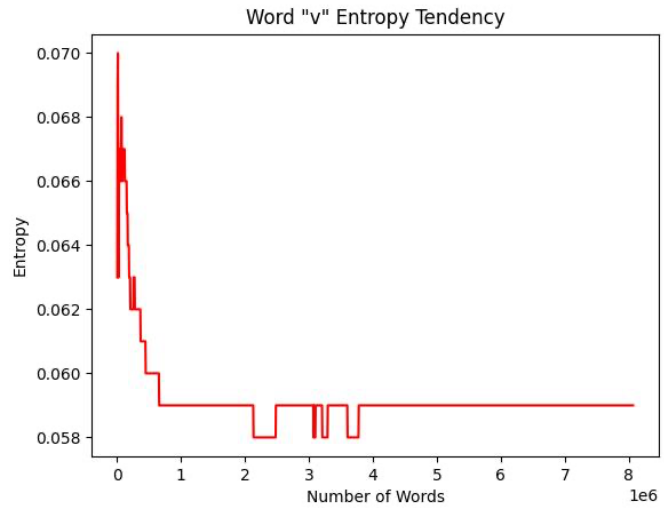
Word "v" Entropy Tendency
Entropy
0.070
0.068
0.066
0.064
0.062
0.060
0.058
0
1
2
3
4
5
6
7
8
Number of Words
1e6

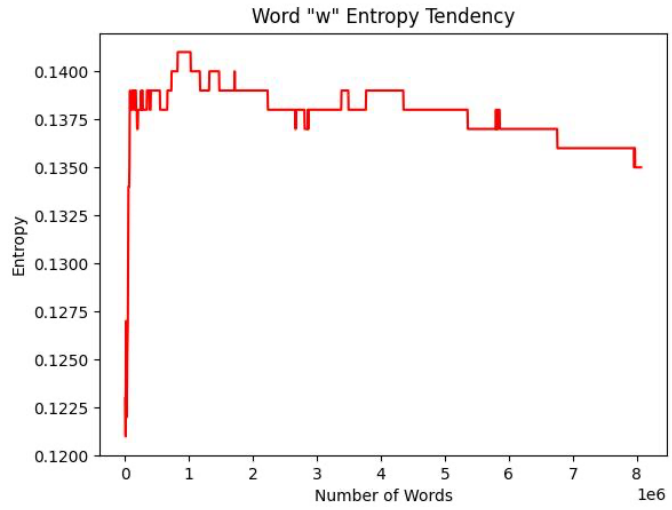
Word "w" Entropy Tendency
Entropy
0.1400
0.1375
0.1350
0.1325
0.1300
0.1275
0.1250
0.1225
0.1200
0
1
2
3
4
5
6
7
8
Number of Words
1e6

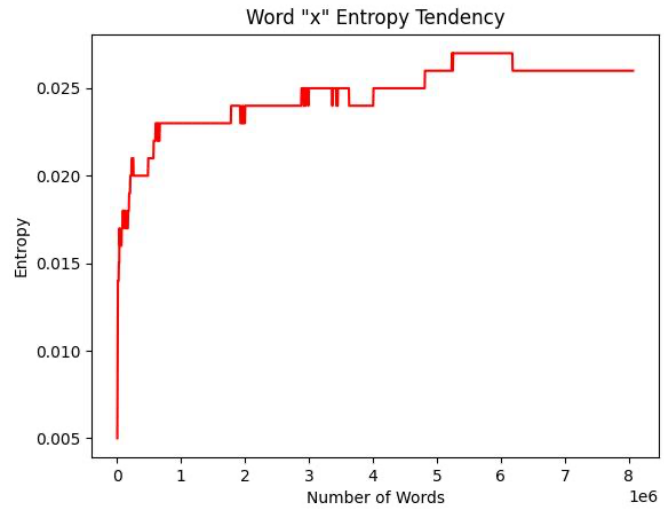
Word "x" Entropy Tendency
Entropy
0.025
0.020
0.015
0.010
0.005
0
1
2
3
4
5
6
7
8
Number of Words
1e6

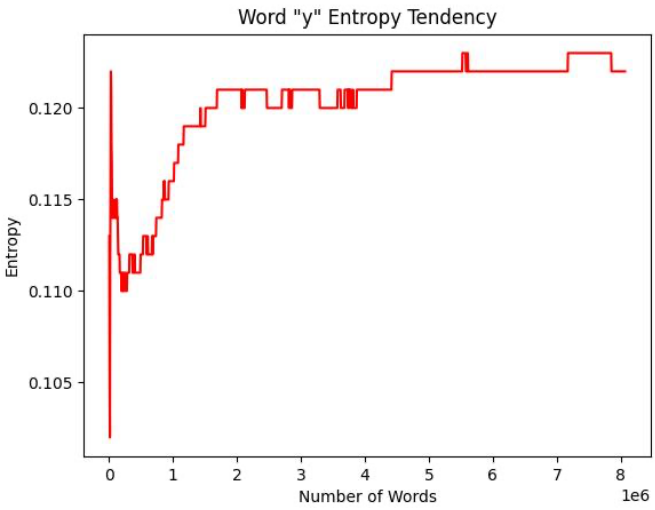
Word "y" Entropy Tendency
Entropy
0.120
0.115
0.110
0.105
0
1
2
3
4
5
6
7
8
Number of Words
1e6

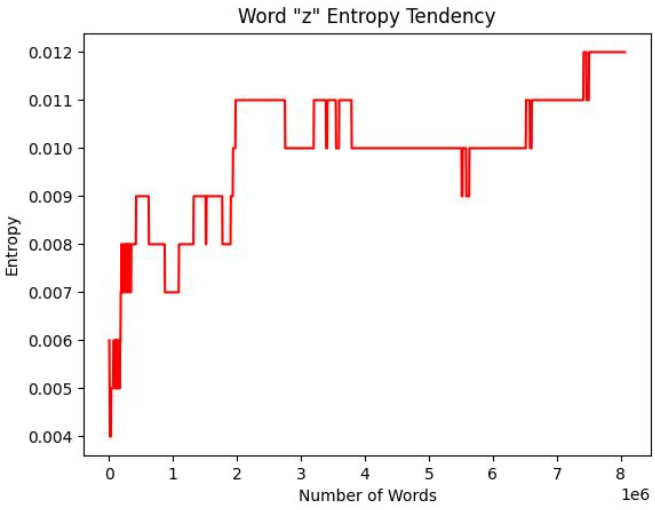
Word "z" Entropy Tendency
Entropy
0.012
0.011
0.010
0.009
0.008
0.007
0.006
0.005
0.004
0
1
2
3
4
5
6
7
8
Number of Words
1e6